ANTEPROYECTO

Título: Predicción del riesgo de suspenso en educación secundaria mediante técnicas de aprendizaje automático: una simulación metodológica aplicada a datos de estudiantes portugueses.

Autor: Manuel Ventosa Rodríguez.

DESCRIPCIÓN DEL PROBLEMA A RESOLVER

Motivación y origen:

La identificación temprana del riesgo de suspenso en educación secundaria constituye una cuestión relevante para los sistemas educativos europeos, especialmente en contextos donde el bajo rendimiento académico y el abandono escolar continúan siendo problemáticas persistentes. En el caso de Portugal, informes internacionales como PISA han puesto de manifiesto la existencia de un porcentaje significativo de alumnado que no alcanza niveles adecuados de competencia académica, lo que refuerza la necesidad de analizar de forma sistemática los factores asociados al rendimiento escolar y al riesgo de fracaso académico.

En este contexto, el análisis de datos educativos se presenta como una herramienta de interés para profundizar en la comprensión del riesgo académico. La disponibilidad de conjuntos de datos estructurados permite aplicar técnicas de analítica educativa y aprendizaje automático con el objetivo de identificar patrones y relaciones entre variables académicas, personales y familiares que influyen en el desempeño del alumnado.

El presente Trabajo Fin de Grado se plantea como una simulación metodológica, orientada a analizar cómo los modelos predictivos pueden aplicarse al estudio del riesgo de suspenso en educación secundaria a partir de datos reales de estudiantes portugueses. El interés del proyecto no reside en la toma de decisiones individuales ni en la implementación directa de políticas educativas, sino en evaluar el potencial de estas técnicas como apoyo al análisis educativo y a la comprensión del fenómeno del bajo rendimiento académico.

Para ello, se emplea el Student Performance Dataset, un conjunto de datos ampliamente utilizado en la literatura científica y procedente de estudiantes portugueses, que recoge información académica, personal y familiar. A partir de esta base, el proyecto pretende analizar qué factores presentan una mayor relación con el riesgo de suspenso y cómo distintos modelos de aprendizaje automático pueden contribuir a su identificación. De este modo, el trabajo se enmarca en una perspectiva aplicada y analítica, alineada con las actuales tendencias en investigación educativa y con las necesidades de diseño de políticas educativas basadas en datos.

Datos que lo sustentan:

El estudio se basa en el *Student Performance Dataset*, procedente del UCI Machine Learning Repository, utilizado como fuente original de los datos. El conjunto recoge información de estudiantes portugueses de educación secundaria e incluye variables académicas, personales y familiares, lo que permite abordar el análisis del riesgo de suspenso desde una perspectiva multidimensional.

El conjunto de datos fue recopilado a partir de estudiantes portugueses de educación secundaria y está compuesto por 649 observaciones, donde cada registro corresponde a un estudiante individual. El dataset contiene un total de 33 variables explicativas, además de las variables correspondientes a las calificaciones académicas obtenidas a lo largo del curso, lo que permite analizar el rendimiento académico desde una perspectiva multidimensional que integra factores personales, familiares, comportamentales y escolares.

Las variables originales incluidas pueden agruparse en los siguientes bloques analíticos, en función de su naturaleza:

En primer lugar, el conjunto de datos incorpora variables demográficas básicas, concretamente age (edad del estudiante) y sex (sexo), que permiten contextualizar el rendimiento académico atendiendo a características personales fundamentales.

En segundo lugar, se incluyen variables familiares y socioeducativas que describen el entorno del alumno. Entre ellas se encuentran Medu y Fedu, que recogen el nivel educativo de la madre y del padre; guardian, que identifica al tutor legal; famsize, que indica el tamaño del núcleo familiar; Pstatus, que refleja la convivencia de los progenitores; y famrel, que mide la calidad de las relaciones familiares. Asimismo, se incorporan variables relacionadas con el apoyo educativo y los recursos disponibles en el hogar, como schoolsup (apoyo educativo adicional proporcionado por el centro), famsup (apoyo educativo familiar), paid (clases particulares), internet (acceso a internet en el hogar) y higher (aspiración a continuar estudios superiores).

En tercer lugar, el dataset recoge variables asociadas a los hábitos, comportamientos y estilo de vida del alumnado, identificadas en la literatura como factores relevantes en el rendimiento académico. En este bloque se incluyen studytime (tiempo dedicado al estudio), failures (número de suspensos previos), absences (número de ausencias), freetime (tiempo libre tras la jornada escolar), goout (frecuencia de salidas con amigos), Dalc (consumo de alcohol entre semana), Walc (consumo de alcohol durante el fin de semana), activities (participación en actividades extracurriculares) y romantic (existencia de relación sentimental).

Por último, el conjunto de datos incorpora variables estrictamente académicas, que reflejan el desempeño del estudiante a lo largo del curso: G1 (nota de la primera evaluación), G2 (nota de la

segunda evaluación) y G3 (calificación final), siendo esta última el principal indicador del rendimiento académico global del alumnado.

Antes de su utilización en el análisis predictivo, el conjunto de datos será sometido a un proceso exhaustivo de preparación y preprocesamiento, que incluirá la verificación de la consistencia de los registros, la codificación adecuada de las variables categóricas, la revisión de posibles valores atípicos y la normalización de aquellas variables numéricas que lo requieran en función del modelo aplicado. Este proceso garantiza la calidad de los datos y la validez metodológica de los resultados.

Con el fin de enriquecer la base de datos original y aumentar la capacidad explicativa de los modelos predictivos, se plantea la creación de un conjunto de variables derivadas, construidas exclusivamente a partir de la información ya existente en el dataset, sin incorporar datos externos ni realizar imputaciones artificiales. En concreto, se propone la generación de las siguientes variables:

- Riesgo de suspenso, definida como una variable binaria derivada de G3, que toma el valor 1 cuando la calificación final es inferior al umbral de aprobado y 0 en caso contrario.
- Media académica parcial, calculada a partir de G1 y G2, que permite capturar el rendimiento acumulado del estudiante durante el curso.
- Progreso académico, definido como la diferencia entre la calificación final y la primera evaluación (G3 − G1), con el objetivo de analizar la evolución del desempeño académico.
- Absentismo elevado, variable indicadora construida a partir de absences, que permite identificar niveles de asistencia asociados a mayor riesgo académico.
- Nivel educativo familiar agregado, obtenido mediante la combinación del nivel educativo de ambos progenitores (Medu y Fedu), como indicador sintético del capital educativo del entorno familiar.
- Indicador de apoyo educativo, variable compuesta que integra schoolsup, famsup, paid e internet, con el fin de capturar la disponibilidad global de recursos educativos para el alumno.
- Consumo medio de alcohol, calculado como el promedio de Dalc y Walc, que permite analizar la relación entre hábitos de consumo y rendimiento académico.

La creación y utilización de estas variables derivadas se llevará a cabo durante el desarrollo del Trabajo Fin de Grado. La inclusión final de cada una de ellas en los modelos predictivos estará sujeta a los resultados del análisis exploratorio de datos y a criterios de relevancia estadística e interpretabilidad, pudiendo descartarse aquellas variables que no aporten valor explicativo adicional o introduzcan redundancia en el modelo.

El conjunto de datos utilizado en este estudio procede del *Student Performance Dataset*, disponible en el UCI Machine Learning Repository, que constituye la fuente original de los datos empleados. Para facilitar la reproducibilidad del análisis, los datos utilizados y los ficheros derivados generados durante el desarrollo del proyecto se adjuntan como material complementario en los siguientes enlaces: (https://drive.google.com/file/d/153hSzS5IkC9nIcYH5nnSouCV3pD4ISFx/view?usp=sharing)

(https://drive.google.com/file/d/1hNBAo2SGDx6cO8Vl8_IbNRoRV6UqhwkM/view?usp=sharing)

Impacto de la solución del problema:

El desarrollo de modelos predictivos aplicados al análisis del riesgo de suspenso puede aportar valor en el ámbito educativo al facilitar una comprensión más estructurada de los factores asociados al bajo rendimiento académico. La solución propuesta permite identificar relaciones relevantes entre variables académicas, personales y familiares, contribuyendo a un análisis más profundo del fenómeno del suspenso en educación secundaria.

En segundo lugar, la identificación de factores asociados al riesgo académico puede servir como apoyo para la toma de decisiones en el diseño de estrategias generales de mejora educativa. Disponer de información basada en datos facilita la detección de situaciones recurrentes vinculadas al suspenso, como determinados hábitos de estudio, niveles de absentismo o características del entorno familiar, lo que permite orientar el análisis hacia colectivos que presentan mayores probabilidades de dificultad académica. De este modo, la solución aporta una base empírica que puede resultar útil para la planificación de actuaciones educativas de carácter general.

Desde una perspectiva institucional, el proyecto aporta una metodología estructurada para el análisis del rendimiento académico mediante técnicas de aprendizaje automático. El valor principal del trabajo reside en mostrar cómo puede organizarse un proceso completo de análisis, desde la preparación y enriquecimiento de los datos hasta la evaluación de distintos modelos predictivos y la interpretación de sus resultados. Este planteamiento metodológico puede servir como referencia para futuros estudios educativos que empleen conjuntos de datos similares o información procedente de sistemas educativos reales.

En conjunto, el proyecto permite analizar el riesgo de suspenso desde una perspectiva basada en datos, aportando una visión estructurada sobre los factores asociados al bajo rendimiento académico en educación secundaria. Los resultados obtenidos pueden servir como información de apoyo para el análisis general del rendimiento escolar y para la reflexión en torno a medidas de apoyo educativo en el contexto del sistema educativo portugués, manteniendo siempre un enfoque descriptivo y metodológico acorde con el alcance del estudio.

Problema de investigación en forma de Pregunta:

La pregunta planteada es la siguiente: ¿En qué medida las variables académicas, personales y familiares recogidas en un conjunto de datos de estudiantes portugueses de educación secundaria permiten identificar el riesgo de suspenso mediante modelos predictivos, y qué factores presentan una mayor relación con dicho riesgo?

Preguntas de investigación:

¿Qué variables académicas se asocian de forma significativa con el riesgo de suspenso en estudiantes de educación secundaria en Portugal?

¿Qué factores personales y familiares presentan una mayor relación con la probabilidad de riesgo académico?

¿Mejora la incorporación de variables derivadas la capacidad predictiva de los modelos frente al uso exclusivo de las variables originales?

¿Qué modelo predictivo de clasificación ofrece un mejor equilibrio entre capacidad predictiva e interpretabilidad para la identificación del riesgo de suspenso?

¿Qué factores resultan más relevantes en la predicción del riesgo académico según el modelo seleccionado?

Planificación del proyecto:

La planificación del proyecto se estructura en una secuencia lógica de fases que permiten abordar de forma progresiva el análisis del problema de investigación, desde la revisión teórica inicial hasta la obtención e interpretación de resultados. Esta planificación describe las tareas y contenidos que se desarrollarán en cada etapa del trabajo, diferenciándose del cronograma, que se centra en la dimensión temporal.

En una primera fase, se llevará a cabo la revisión de la literatura científica relacionada con el rendimiento académico, el fracaso escolar y la aplicación de técnicas de analítica educativa y aprendizaje automático en el ámbito educativo. Esta fase permitirá construir el marco teórico del proyecto, identificar los principales factores asociados al riesgo académico según estudios previos y justificar la elección de los modelos predictivos empleados.

En una segunda fase, se realizará la comprensión y descripción detallada del conjunto de datos seleccionado. Se analizará la estructura del Student Performance Dataset, su origen, el significado de las variables incluidas y su adecuación al problema de investigación. Asimismo, se llevará a cabo un proceso de preparación de los datos que incluirá la limpieza, la codificación de variables categóricas y la definición de la variable objetivo.

La tercera fase se centrará en el enriquecimiento del dataset mediante la creación de variables derivadas, construidas a partir de la información existente. Estas variables permitirán captar de forma más precisa conceptos relevantes para el análisis del riesgo académico, como el rendimiento previo, el absentismo o el entorno familiar, y serán evaluadas posteriormente durante el análisis exploratorio.

A continuación, se desarrollará una fase de análisis exploratorio de los datos, cuyo objetivo será identificar patrones, relaciones entre variables y posibles problemas de colinealidad. Este análisis servirá como base para la selección de variables y para la toma de decisiones metodológicas previas al modelado predictivo.

En la siguiente fase, se procederá al desarrollo y comparación de distintos modelos predictivos de clasificación, concretamente regresión logística, árbol de decisión y random forest. Se evaluará el rendimiento de cada modelo mediante métricas adecuadas al problema y se analizará su capacidad predictiva e interpretabilidad, con el fin de seleccionar el enfoque más adecuado.

Posteriormente, se llevará a cabo la interpretación de los resultados obtenidos, prestando especial atención a la identificación de los factores con mayor relevancia en la predicción del riesgo de suspenso. Esta fase permitirá relacionar los resultados empíricos con la literatura revisada y responder a las preguntas de investigación planteadas.

Finalmente, se elaborará la redacción final del Trabajo Fin de Grado, integrando el marco teórico, la metodología, los resultados y las conclusiones. En esta etapa se incluirá también una reflexión sobre el alcance del estudio y sobre la utilidad de los resultados para el análisis general y la toma de decisiones en materia de apoyo educativo en el contexto del sistema educativo portugués.

Estado del arte:

El rendimiento académico del alumnado en educación secundaria constituye una de las principales áreas de interés en la investigación educativa contemporánea. La preocupación por el bajo rendimiento, el fracaso escolar y el abandono educativo temprano ha motivado a instituciones académicas, organismos internacionales y administraciones públicas a analizar en profundidad los factores que influyen en la trayectoria educativa de los estudiantes. En el contexto europeo, estos fenómenos adquieren especial relevancia debido a su impacto directo en la empleabilidad, la cohesión social y el desarrollo económico a largo plazo.

Tradicionalmente, el análisis del rendimiento académico se ha abordado desde enfoques descriptivos basados en indicadores agregados como tasas de aprobados, repetición de curso o abandono escolar. Aunque estos estudios han permitido identificar tendencias generales y realizar comparaciones entre países o sistemas educativos, han mostrado limitaciones significativas para explicar las causas subyacentes del bajo rendimiento a nivel individual. Como consecuencia, la literatura educativa ha evolucionado progresivamente hacia enfoques más integradores que consideran el rendimiento

académico como el resultado de la interacción entre múltiples dimensiones de carácter académico, personal, familiar y contextual.

Numerosos estudios han demostrado que el rendimiento académico no depende exclusivamente de las capacidades cognitivas del alumnado. Variables como el entorno familiar, el nivel educativo de los progenitores, el apoyo educativo disponible en el hogar, los hábitos de estudio y la trayectoria académica previa influyen de manera significativa en la probabilidad de éxito o fracaso escolar. En este sentido, investigaciones desarrolladas en distintos países europeos coinciden en señalar que el capital educativo familiar actúa como un factor estructural clave, condicionando tanto las expectativas académicas como el acceso a recursos educativos.

El papel del entorno familiar ha sido ampliamente documentado en la literatura científica. Diversos trabajos ponen de manifiesto que el nivel educativo de los padres se asocia de forma consistente con el rendimiento académico del alumnado, actuando como un indicador del capital cultural y del apoyo potencial al aprendizaje. Asimismo, la estabilidad del entorno familiar y la calidad de las relaciones intrafamiliares han sido identificadas como factores relevantes, especialmente en etapas educativas sensibles como la educación secundaria. Estos resultados refuerzan la importancia de incorporar variables familiares en los análisis del riesgo académico.

Junto a los factores familiares, la literatura ha subrayado la influencia de los hábitos y comportamientos del alumnado en su desempeño escolar. Variables como el tiempo dedicado al estudio, la regularidad en la asistencia a clase y la participación en actividades educativas complementarias han mostrado una relación positiva con el rendimiento académico. En particular, el absentismo escolar ha sido identificado como uno de los predictores más robustos del riesgo de suspenso y abandono educativo. Estudios longitudinales indican que niveles elevados de ausencias incrementan significativamente la probabilidad de bajo rendimiento, incluso cuando se controlan otras variables sociodemográficas.

Además, diversos trabajos han analizado la relación entre determinados hábitos de ocio y estilo de vida y el rendimiento académico. Investigaciones centradas en el consumo de alcohol, la gestión del tiempo libre o la frecuencia de actividades sociales sugieren que estos comportamientos, cuando se combinan con bajo compromiso académico, pueden aumentar el riesgo de suspenso. Estos estudios no interpretan dichos factores de forma aislada, sino como parte de un conjunto de variables que interactúan y configuran distintos perfiles de riesgo.

En paralelo a estos enfoques más tradicionales, en las últimas décadas ha emergido con fuerza el campo de la analítica educativa, que aplica técnicas de análisis de datos y aprendizaje automático al estudio de fenómenos educativos. Este ámbito parte de la premisa de que los sistemas educativos generan grandes volúmenes de datos que, analizados mediante metodologías adecuadas, pueden

proporcionar información valiosa para comprender el comportamiento del alumnado y los factores asociados al rendimiento académico.

Dentro de la analítica educativa, una de las líneas de investigación más consolidadas es la predicción del rendimiento académico y del riesgo de suspenso mediante modelos de aprendizaje automático. Numerosos estudios han demostrado que los modelos de clasificación supervisada son capaces de identificar patrones complejos en los datos educativos que no resultan evidentes mediante técnicas estadísticas tradicionales. Este enfoque ha permitido avanzar desde análisis puramente descriptivos hacia modelos con capacidad explicativa y predictiva.

Uno de los trabajos más relevantes y citados en este ámbito es el estudio desarrollado por Cortez y Silva (2008) en la Universidad de Minho, en Portugal. En dicho proyecto, los autores analizaron el rendimiento académico de estudiantes de educación secundaria utilizando técnicas de minería de datos aplicadas al Student Performance Dataset. Emplearon modelos como la regresión logística, los árboles de decisión y las redes neuronales artificiales para predecir la calificación final del alumnado a partir de variables académicas, familiares y personales. Los resultados mostraron que el rendimiento previo, el número de ausencias y determinadas características del entorno familiar eran factores clave en la predicción del riesgo de suspenso. Este estudio constituye un referente fundamental en la literatura, tanto por el enfoque metodológico adoptado como por el uso de datos reales de estudiantes portugueses.

Posteriormente, otros proyectos académicos han replicado y ampliado este enfoque en distintos contextos educativos. Kotsiantis et al. (2004) desarrollaron un estudio comparativo en el que evaluaron diversos algoritmos de clasificación para la predicción del éxito académico en contextos educativos. Los autores concluyeron que los modelos de clasificación supervisada resultan especialmente adecuados para identificar estudiantes con mayor probabilidad de bajo rendimiento, destacando la importancia de combinar capacidad predictiva e interpretabilidad, especialmente cuando los resultados se destinan a apoyar procesos de análisis educativo.

En el ámbito europeo, Thai-Nghe, Drumond y Schmidt-Thieme (2010) desarrollaron un sistema predictivo orientado a la identificación temprana de estudiantes en riesgo académico, aplicando técnicas de aprendizaje automático a datos educativos reales. Sus resultados subrayan que la predicción temprana del rendimiento permite comprender mejor la evolución académica del alumnado y detectar situaciones problemáticas antes de que se materialicen en suspensos o abandono educativo. Este enfoque refuerza la utilidad de los modelos predictivos como herramientas de análisis y apoyo en el ámbito educativo.

Más recientemente, Fauzan et al. (2020) llevaron a cabo un estudio comparativo de distintos algoritmos de aprendizaje automático aplicados a la predicción del rendimiento académico. En su trabajo, los autores analizaron el desempeño de modelos como árboles de decisión y bosques

aleatorios, concluyendo que los modelos de conjunto ofrecen un equilibrio adecuado entre precisión y estabilidad. Asimismo, destacaron que la interpretabilidad sigue siendo un aspecto clave en contextos educativos, lo que justifica la comparación entre modelos simples y modelos más complejos.

Las revisiones sistemáticas también han contribuido de forma significativa a consolidar este campo de investigación. Romero y Ventura (2020) realizaron una revisión exhaustiva de más de una década de estudios en minería de datos educativa, identificando la predicción del rendimiento académico como una de las aplicaciones más desarrolladas. Los autores señalan que los estudios más robustos combinan variables académicas, personales y familiares, incorporan procesos de ingeniería de variables y comparan distintos modelos predictivos para evaluar su rendimiento y su capacidad explicativa.

Un elemento recurrente en la literatura es la relevancia de la ingeniería de variables como parte fundamental del análisis predictivo. Diversos estudios destacan que la creación de variables derivadas, como medias académicas parciales, indicadores de absentismo o agregados del entorno familiar, mejora de forma significativa la capacidad predictiva de los modelos. Este enfoque permite transformar la información original en variables más representativas de los conceptos que se desean analizar, incrementando tanto la precisión como la interpretabilidad de los resultados.

Asimismo, la literatura enfatiza la importancia de seleccionar métricas de evaluación adecuadas al problema educativo. Dado que el interés principal suele centrarse en la identificación de estudiantes en riesgo, métricas como el recall o el F1-score adquieren especial relevancia frente a medidas globales como la accuracy. Este énfasis refleja la necesidad de minimizar los falsos negativos, es decir, aquellos casos en los que el modelo no identifica a estudiantes que realmente presentan riesgo académico.

En el contexto de la política educativa y el análisis institucional, organismos internacionales como la OCDE han señalado el potencial del análisis de datos para mejorar la comprensión de los factores asociados al bajo rendimiento y al abandono educativo temprano. Aunque estos informes no desarrollan modelos predictivos específicos, sí ponen de manifiesto la necesidad de avanzar hacia enfoques basados en evidencia empírica que permitan orientar el diseño general de medidas de apoyo educativo.

En conjunto, la revisión de la literatura pone de manifiesto que el rendimiento académico es un fenómeno complejo, determinado por la interacción de múltiples factores académicos, personales y familiares, y que las técnicas de aprendizaje automático ofrecen herramientas adecuadas para su análisis. No obstante, también se identifica la necesidad de estudios que integren de forma coherente datos reales, procesos de enriquecimiento del dataset, comparación de modelos predictivos y análisis interpretativo de los resultados.

En este marco se sitúa el presente trabajo fin de grado, que adopta un enfoque alineado con las investigaciones previas y contribuye a este ámbito mediante el análisis del riesgo de suspenso en educación secundaria a partir de datos reales de estudiantes portugueses. El proyecto se orienta a comparar distintos modelos predictivos, analizar la relevancia de los factores asociados al bajo rendimiento y aportar una metodología estructurada que permita comprender mejor el fenómeno del riesgo académico desde una perspectiva basada en datos.

Bibliografía en formato APA:

Cortez, P., & Silva, A. (2008). Using data mining to predict secondary school student performance. *Proceedings of the 5th Future Business Technology Conference*, 5–12.

Fauzan, R., Abdullah, D., Faiz, N., & Mohamad, M. (2020). Comparison of machine learning algorithms for student performance prediction. *Procedia Computer Science, 170*, 32–39.

Kotsiantis, S. B., Pierrakeas, C., & Pintelas, P. (2004). Predicting students' performance in distance learning using machine learning techniques. *Applied Artificial Intelligence, 18*(5), 411–426.

Organisation for Economic Co-operation and Development. (2019). *PISA 2018 results (Volume I): What students know and can do*. OECD Publishing.

Organisation for Economic Co-operation and Development. (2023). *Education at a glance 2023: OECD indicators*. OECD Publishing.

Romero, C., & Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 10*(3), e1355.

Thai-Nghe, N., Drumond, L., & Schmidt-Thieme, L. (2010). Recommender system for predicting student performance. *Procedia Computer Science, 1*(2), 2811–2819.

Objetivo general y objetivos específicos

OBJETIVO GENERAL

Analizar el riesgo de suspenso en estudiantes de educación secundaria en Portugal mediante técnicas de aprendizaje automático, con el fin de identificar los factores asociados al bajo rendimiento académico y evaluar el comportamiento de distintos modelos predictivos.

OBJETIVOS ESPECÍFICOS

1. Revisar la literatura científica sobre rendimiento académico y analítica educativa.
2. Describir y preparar el conjunto de datos utilizado.
3. Crear variables derivadas relevantes para el análisis del riesgo académico.

4. Aplicar y comparar distintos modelos predictivos de clasificación.
5. Analizar la importancia de las variables en la predicción del riesgo de suspenso.
6. Evaluar la utilidad de los resultados para el análisis general del rendimiento académico.

METODOLOGÍA

1. Planteamiento del problema como clasificación supervisada

El problema de investigación se formula como un problema de clasificación supervisada, en el que el objetivo es identificar la probabilidad de que un estudiante se encuentre en situación de riesgo de suspenso. Esta formulación se justifica porque el interés principal del estudio no reside en predecir una calificación numérica exacta, sino en identificar situaciones de riesgo académico que puedan ser analizadas de forma agregada.

Para ello, se define una variable objetivo binaria derivada de la calificación final del alumnado, lo que permite interpretar los resultados en términos de probabilidad y facilita la comparación entre distintos modelos predictivos. Esta aproximación es ampliamente utilizada en la literatura de analítica educativa y resulta especialmente adecuada para estudios orientados a la identificación de factores de riesgo.

2. Selección de modelos predictivos

La selección de los modelos predictivos en este Trabajo Fin de Grado responde a la necesidad de analizar el riesgo de suspenso en educación secundaria desde una perspectiva comparativa, combinando capacidad predictiva e interpretabilidad. Dado que el objetivo del proyecto no se limita a clasificar estudiantes en función de su riesgo académico, sino a identificar y analizar los factores que presentan una mayor relación con dicho riesgo, se seleccionan modelos que permiten responder a ambas dimensiones del problema.

En este contexto, se emplean tres modelos de clasificación supervisada: regresión logística, árbol de decisión y random forest. Estos modelos se aplican sobre el mismo conjunto de datos y bajo las mismas condiciones de preprocesamiento, lo que permite comparar su comportamiento y evaluar qué enfoque resulta más adecuado para el análisis del riesgo académico en el contexto educativo portugués.

La regresión logística se utiliza como modelo de referencia debido a su capacidad para estimar probabilidades de riesgo y a su elevada interpretabilidad. En el marco de este estudio, la regresión logística permite analizar de forma directa cómo variables como el rendimiento académico previo, el absentismo, el nivel educativo de los progenitores o el apoyo educativo en el hogar se asocian con la probabilidad de suspenso. La interpretación de los coeficientes facilita identificar qué factores incrementan o reducen el riesgo académico y en qué medida, lo que resulta especialmente relevante para comprender el fenómeno del bajo rendimiento más allá de la mera predicción.

El árbol de decisión se incorpora para analizar cómo la combinación de distintas variables da lugar a perfiles diferenciados de riesgo académico. A diferencia de la regresión logística, este modelo permite capturar relaciones no lineales e interacciones entre factores, lo que resulta adecuado en un contexto educativo donde el riesgo de suspenso no depende de un único factor aislado, sino de la interacción entre variables académicas, personales y familiares. En este trabajo, el árbol de decisión permite identificar reglas de clasificación que muestran, por ejemplo, cómo determinados niveles de absentismo combinados con bajo rendimiento previo o escaso apoyo educativo se asocian a un mayor riesgo de suspenso, facilitando así la interpretación de los resultados.

Por su parte, el random forest se selecciona con el objetivo de evaluar un enfoque más robusto desde el punto de vista predictivo. Al combinar múltiples árboles de decisión, este modelo reduce el riesgo de sobreajuste y suele ofrecer una mayor estabilidad en la predicción del riesgo académico. En el contexto del presente estudio, el random forest permite analizar si la incorporación de un modelo de mayor complejidad mejora de forma significativa la capacidad de identificar estudiantes en riesgo frente a modelos más simples. Asimismo, las medidas de importancia de variables que proporciona este modelo permiten contrastar qué factores aparecen de forma consistente como relevantes en la predicción del riesgo de suspenso.

La utilización conjunta de estos tres modelos permite abordar el problema de investigación desde perspectivas complementarias. Mientras que la regresión logística facilita la comprensión individual del efecto de cada variable, el árbol de decisión aporta una visión basada en perfiles y reglas interpretables, y el random forest permite evaluar el máximo rendimiento predictivo alcanzable con los datos disponibles. Esta estrategia comparativa resulta coherente con los objetivos del proyecto y con la literatura en analítica educativa, y permite valorar de forma crítica el equilibrio entre precisión predictiva e interpretabilidad en el análisis del riesgo académico.

3. Estrategia de comparación de modelos

La comparación entre los modelos se realizará de forma sistemática y homogénea. Todos los modelos se entrenarán utilizando el mismo conjunto de datos, con idéntico proceso de preprocesamiento y la misma partición en subconjuntos de entrenamiento y prueba. Esta estrategia garantiza que las diferencias observadas en el rendimiento de los modelos sean atribuibles al algoritmo empleado y no a variaciones en los datos utilizados.

4. Métricas de evaluación y justificación

La evaluación del rendimiento de los modelos se realizará utilizando un conjunto de métricas complementarias que permiten analizar distintos aspectos del comportamiento predictivo. En primer lugar, se empleará la accuracy como medida global del porcentaje de clasificaciones correctas. No

obstante, esta métrica se utilizará de forma contextualizada, dado que puede resultar insuficiente en problemas donde la detección del riesgo es prioritaria.

Para evaluar la calidad de las predicciones en la categoría de riesgo, se emplearán la precisión y el recall. La precisión permite analizar la fiabilidad de las predicciones de riesgo, mientras que el recall mide la capacidad del modelo para identificar correctamente a los estudiantes que realmente presentan riesgo de suspenso. Esta última métrica adquiere especial relevancia en el contexto del estudio, ya que no identificar casos de riesgo puede limitar la utilidad del análisis.

Asimismo, se utilizará el F1-score como métrica de equilibrio entre precisión y recall, proporcionando una visión integrada del desempeño del modelo. Finalmente, se analizarán las matrices de confusión para examinar de forma detallada los errores de clasificación y comprender mejor el comportamiento de cada modelo.

La selección de estas métricas responde a la necesidad de evaluar los modelos desde una perspectiva educativa, priorizando la identificación del riesgo académico frente a una evaluación puramente técnica del rendimiento.

5. Interpretación de resultados

Una vez evaluados los modelos, se analizarán los resultados obtenidos en relación con los objetivos y preguntas de investigación planteadas.

Esta fase final permite conectar los resultados empíricos con la literatura revisada y valorar la utilidad de los modelos predictivos como herramientas de análisis del riesgo de suspenso en educación secundaria, manteniendo un enfoque descriptivo y analítico acorde con el alcance del proyecto.

6. Ejemplos previos

La metodología se apoya en estudios previos como el desarrollado por Cortez y Silva (2008), que aplicaron modelos predictivos al rendimiento de estudiantes portugueses utilizando el mismo dataset, así como en trabajos posteriores que comparan distintos algoritmos de clasificación en contextos educativos.

7. Limitaciones metodológicas

El análisis se basa en un único conjunto de datos, lo que limita la generalización de los resultados a otros contextos educativos. Asimismo, los modelos predictivos permiten identificar asociaciones estadísticas, pero no establecer relaciones causales entre variables y rendimiento académico.

CRONOGRAMA

Fase 1 — Revisión teórica y planteamiento del estudio

Duración: noviembre – diciembre

Entregables:

- Revisión de literatura científica relevante.
- Elaboración del estado del arte.
- Definición del problema de investigación, objetivos y preguntas de investigación.

Fase 2 — Preparación y comprensión del conjunto de datos

Duración: enero

Entregables:

- Dataset obtenido de la fuente original del UCI Machine Learning Repository.
- Limpieza y preprocesamiento de los datos.
- Definición de la variable objetivo.

Fase 3 — Enriquecimiento del dataset y análisis exploratorio

Duración: febrero

Entregables:

- Creación de variables derivadas.
- Análisis exploratorio de datos.
- Identificación de patrones y relaciones relevantes.

Fase 4 — Modelado predictivo y evaluación

Duración: marzo

- Entrenamiento de modelos predictivos (regresión logística, árbol de decisión y random forest).
- Evaluación del rendimiento mediante métricas adecuadas.
- Comparación de modelos.

Fase 5 — Interpretación de resultados y redacción final

Duración: abril – mayo

Entregables:

- Análisis de la importancia de las variables.
- Discusión de resultados y conclusiones.
- Redacción final de la memoria y preparación de la defensa.