MEMORIA JUSTIFICATIVA PARA LA ACEPTACIÓN DEL ANTEPROYECTO

Título: Análisis predictivo del riesgo de suspenso en estudiantes: simulación de un caso de consultoría para la Consejería de Educación de Madrid.

Autor: Manuel Ventosa Rodríguez.

DESCRIPCIÓN DEL PROBLEMA A RESOLVER

Motivación y origen:

La persistencia del suspenso y la no continuidad hacia el Bachillerato sigue siendo una preocupación crítica en el sistema educativo madrileño. Aunque la tasa de abandono educativo temprano en la Comunidad de Madrid se ha situado en torno al 10,5 %, este valor sigue representando a miles de jóvenes que no alcanzan el nivel formativo necesario para integrarse con éxito en el mercado laboral.

Además, siguiendo datos del Ministerio de Educación y Formación Profesional, el 28,7 % del alumnado madrileño de 4º de ESO ha repetido curso al menos una vez durante su etapa educativa. La repetición constituye uno de los indicadores más estrechamente vinculados al fracaso escolar y a la probabilidad de no acceder a Bachillerato, lo que refuerza la necesidad de desplegar intervenciones tempranas y políticas basadas en evidencia.

Dado que la acumulación de repeticiones y los suspensos persistentes son los principales determinantes de la no continuidad hacia el Bachillerato, resulta esencial identificar de manera anticipada a los estudiantes en riesgo para evitar que su trayectoria académica se vea comprometida.

En este marco, la Consejería de Educación de Madrid plantea la contratación de un servicio de consultoría analítica para identificar qué factores personales, sociales y escolares se relacionan de manera más intensa con el riesgo de suspenso, con el objetivo de optimizar la asignación de ayudas, tutorías y programas de refuerzo educativo.

El presente trabajo se enmarca como una simulación de dicho encargo: mediante el uso del Student Performance Dataset del UCI Machine Learning Repository, el autor realiza un análisis metodológico adaptado al contexto madrileño para detectar perfiles de estudiantes vulnerables, sin emplear datos reales de la administración. Esta aproximación permite evaluar la aplicabilidad de herramientas predictivas en la orientación estratégica de recursos educativos, garantizando al mismo tiempo la confidencialidad, la ética y la escalabilidad de la solución.

Este proyecto aporta una contribución original al aplicar metodologías de analítica educativa a un caso de consultoría simulado, basado en un problema real de política pública, integrando modelos

predictivos interpretables, criterios éticos y un enfoque orientado a la toma de decisiones institucionales.

Datos que lo sustentan:

El análisis se apoya en el Student Performance Dataset, publicado por el UCI Machine Learning Repository, que recoge información real de estudiantes de dos centros educativos. Aunque el dataset original proviene de Portugal, en este trabajo se utiliza como simulación metodológica aplicada al contexto madrileño, dado que su estructura y tipos de variables coinciden con los factores que habitualmente se analizan en estudios de rendimiento escolar.

Este dataset contiene atributos académicos, familiares, sociales y conductuales que permiten estudiar patrones de riesgo académico. Incluye, entre otros:

- Variables personales: edad, género, relación familiar, actividades extraescolares.
- Variables sociofamiliares: nivel educativo de los padres, ocupación, apoyo familiar.
- Variables escolares: tiempo de estudio semanal, número de ausencias, apoyo escolar, participación en tutorías.
- Rendimiento académico: tres notas finales del curso (G1, G2 y G3), que permiten modelar la probabilidad de suspenso.

Para adaptar el dataset al contexto madrileño se han realizado dos operaciones metodológicas justificadas:

Recontextualización de los centros educativos:

Los códigos originales de escuela (“GP” y “MS”) se reinterpretan como dos centros madrileños ficticios, para simular un encargo por parte de la Consejería de Educación. Esta adaptación no altera la integridad del dataset, únicamente su etiqueta contextual.

Simulación de un caso real sin comprometer datos sensibles:

El uso de datos procedentes de UCI permite evaluar la viabilidad técnica y predictiva del modelo sin necesitar acceso a datos protegidos del sistema educativo español. De este modo, se reproduce el tipo de análisis que podría aplicarse sobre registros reales de Madrid garantizando privacidad y ética.

Este dataset es incluye los principales factores reconocidos en la literatura científica como predictores del rendimiento académico: apoyo familiar, tiempo de estudio, absentismo, implicación escolar y entorno socioeconómico. Estos elementos coinciden plenamente con los que evalúa la Consejería de Educación en sus políticas de prevención del fracaso escolar.

En el desarrollo del TFG, este conjunto de datos se procesará en RStudio para realizar:

- Limpieza y preparación de datos.
- Análisis exploratorio.
- Creación de variables derivadas.
- Modelado predictivo.
- Estimación del riesgo de suspenso.
- Identificación de perfiles vulnerables.

Todo ello permitirá replicar, en un entorno controlado, el flujo de trabajo que seguiría un análisis llevado a cabo sobre datos reales de estudiantes de Madrid.

Los datos empleados en este estudio se encuentran disponibles de forma pública y pueden consultarse en el repositorio desde los siguientes enlaces, que recoge íntegramente los archivos utilizados en este proyecto.

(https://drive.google.com/file/d/153hSzS5IkC9nIcYH5nnSouCV3pD4ISFx/view?usp=sharing)

(https://drive.google.com/file/d/1hNBAo2SGDx6cO8Vl8_IbNRoRV6UqhwkM/view?usp=sharing)

Impacto de la solución del problema:

La identificación temprana del riesgo de suspenso tiene un impacto directo y significativo en la planificación educativa y en la optimización de los recursos públicos. Para la Consejería de Educación de Madrid, contar con un modelo predictivo que permita detectar a los estudiantes más vulnerables, facilita la toma de decisiones basada en evidencia, mejorando la eficiencia de las políticas públicas.

En primer lugar, el uso de un sistema analítico permite priorizar la asignación de ayudas educativas —becas, refuerzo académico, tutorías individualizadas, programas de apoyo emocional o sociofamiliar— hacia aquellos perfiles con mayor probabilidad de suspender y, por tanto, con mayor riesgo de no acceder al Bachillerato. Esto contribuye a una inversión más estratégica de los recursos disponibles, evitando distribuirlos de manera uniforme y poco efectiva.

En segundo lugar, el análisis predictivo ofrece una visión anticipada de los factores que condicionan el rendimiento escolar. Entender la importancia relativa de variables como el tiempo de estudio, la presencia o ausencia de apoyo familiar, el absentismo o el nivel socioeconómico permite diseñar intervenciones preventivas más precisas, actuando sobre los determinantes reales del rendimiento escolar.

En tercer lugar, este tipo de análisis favorece la reducción del fracaso escolar a medio y largo plazo, al posibilitar intervenciones más informadas que mitiguen la probabilidad de repetición y abandono. Un sistema de detección temprana se traduce, por tanto, en un aumento potencial de las tasas de continuidad educativa y de acceso a Bachillerato.

Por último, la incorporación de modelos predictivos dentro de la administración educativa refuerza la modernización de la gestión pública, al incorporar metodologías propias de la inteligencia de negocio y del análisis avanzado de datos. Esto supone una oportunidad para profesionalizar la toma de decisiones y avanzar hacia políticas educativas más transparentes, evaluables y centradas en el impacto social.

En conjunto, la propuesta no solo permite optimizar la asignación de recursos públicos, sino que también introduce un modelo replicable y escalable que podría integrarse en sistemas institucionales de seguimiento académico. Su valor reside en ofrecer una herramienta rigurosa, transparente y alineada con principios éticos que facilita una toma de decisiones más informada por parte de los responsables educativos.

Problema de investigación en forma de Pregunta:

Las administraciones educativas, como la Consejería de Educación de Madrid, gestionan una gran cantidad de información académica y socioeducativa, pero no siempre cuentan con herramientas analíticas que les permitan evaluar, de manera estructurada, qué factores están más relacionados con el riesgo de suspenso. Ante esta realidad, surge la necesidad de explorar cómo un modelo predictivo puede servir como herramienta orientativa para comprender mejor los patrones que explican las dificultades académicas.

El presente proyecto se plantea como una simulación metodológica aplicada al contexto madrileño, en la que se analiza un conjunto de datos educativo representado por dos centros ficticios. A partir de esta simulación, se formula la siguiente pregunta de investigación central:

¿Qué factores personales, familiares y escolares influyen significativamente en el riesgo de suspenso en secundaria y de qué manera un modelo predictivo, aplicado a un caso simulado y basado en técnicas de analítica educativa, puede apoyar de forma rigurosa y ética la toma de decisiones institucionales?

Preguntas de investigación:

¿Qué variables del ámbito personal, sociofamiliar y escolar presentan una relación significativa con el rendimiento académico y con la probabilidad de suspenso?

¿Qué tipo de modelo predictivo ofrece un mejor desempeño en la estimación del riesgo académico dentro del contexto simulado?

¿Qué diferencias de riesgo académico pueden observarse entre los dos escenarios escolares representados en el dataset simulado, sin atribuir dichas diferencias a centros reales?

¿Qué perfiles de estudiantes muestran un riesgo más elevado de suspender y, por tanto, mayores dificultades para continuar hacia Bachillerato?

¿De qué manera podrían los resultados del modelo contribuir, de forma general, a orientar decisiones sobre intervenciones educativas y apoyos al alumnado?

¿Qué consideraciones éticas y de equidad deben tenerse en cuenta al emplear modelos predictivos aplicados al ámbito educativo?

Planificación del proyecto:

Fase 1 — Revisión teórica y contextual

Periodo: 11 de noviembre – 30 de diciembre

Objetivo: definir el marco conceptual y contextualizar el caso simulado.

Tareas principales:

- Revisión bibliográfica sobre analítica educativa, modelos predictivos y factores de riesgo académico.
- Análisis de informes oficiales de Madrid (abandono, repetición, equidad).
- Delimitación final del caso simulado de consultoría.
- Redacción del marco teórico preliminar.

Fase 2 — Preparación y análisis exploratorio de datos

Periodo: 1 – 31 de enero

Objetivo: preparar el dataset para el análisis predictivo.

Tareas principales:

- Limpieza y estructuración del Student Performance Dataset.
- Recontextualización de los centros educativos al escenario madrileño simulado.
- Tratamiento de datos faltantes y codificación de variables categóricas.
- Análisis exploratorio en RStudio.
- Identificación preliminar de patrones y variables relevantes.

Fase 3 — Modelado predictivo y validación

Periodo: 1 – 28 de febrero

Objetivo: construir y evaluar modelos predictivos del riesgo de suspenso.

Tareas principales:

- División del conjunto de datos.

- Entrenamiento de modelos.
- Comparación mediante métricas.
- Análisis de importancia de variables.
- Selección del modelo con mejor equilibrio entre precisión e interpretabilidad.

Fase 4 — Informe consultivo y visualizaciones

Periodo: 1 – 31 de marzo

Objetivo: traducir los resultados en información útil para la toma de decisiones educativas.

Tareas principales:

- Elaboración del informe consultivo orientado a la Consejería de Educación de Madrid.
- Redacción de conclusiones y consideraciones éticas.
- Integración visual y narrativa de los resultados.

Fase 5 — Redacción final de la memoria y preparación de la defensa

Periodo: 1 de abril – mayo

Objetivo: preparar la entrega final y la defensa del TFG.

Tareas principales:

- Redacción completa de la memoria final del TFG.
- Revisión detallada de coherencia, estilo y formato académico.
- Preparación de la presentación oral: estructura, gráficos, narrativa y recomendaciones.
- Ensayos de defensa.

Defensa del TFG: mayo.

<u>Estado del arte:</u>

Predicción del rendimiento académico y analítica educativa en contextos escolares

La predicción del rendimiento académico y la identificación temprana de estudiantes en riesgo constituyen áreas de investigación consolidadas dentro de la Minería de Datos Educativa (Educational Data Mining) y la Analítica del Aprendizaje (Learning Analytics). Ambas disciplinas han evolucionado de manera notable desde principios de los años 2000, impulsadas por la digitalización de los sistemas educativos, la disponibilidad creciente de datos y el desarrollo de técnicas de aprendizaje automático. El objetivo central consiste en comprender patrones complejos de aprendizaje y, especialmente, anticipar dificultades con el fin de diseñar intervenciones más eficaces y equitativas.

Históricamente, gran parte de la investigación se ha centrado en el rendimiento académico como indicador clave del éxito escolar y predictor fundamental de la continuidad educativa. La preocupación por el fracaso escolar y el abandono temprano ha llevado a gobiernos, instituciones educativas y organismos internacionales a promover investigaciones orientadas a comprender las causas estructurales, personales y escolares que determinan si un estudiante consigue alcanzar los niveles educativos mínimos necesarios para su integración socioeconómica. En este contexto, la analítica educativa surge como una herramienta poderosa para analizar grandes volúmenes de datos y generar información útil para la toma de decisiones en el ámbito pedagógico y en la política pública.

1. Analítica educativa y modelos predictivos

Los primeros trabajos que aplicaron técnicas de minería de datos al ámbito educativo demostraron que era posible predecir de manera fiable el rendimiento académico a partir de características del estudiante y del entorno. Uno de los estudios más relevantes es el de Cortez y Silva (2008), que empleó algoritmos de regresión, árboles de decisión y redes neuronales para predecir el rendimiento de estudiantes de secundaria. Su contribución fue doble: por un lado, confirmó la utilidad de estos modelos para identificar patrones de riesgo; por otro, introdujo un conjunto de datos que se convertiría en un referente internacional para la investigación educativa.

Baker e Inventado (2014) amplían este enfoque al vincularlo al campo emergente de la Analítica del Aprendizaje. Los autores explican que las técnicas de minería de datos permiten descubrir patrones invisibles para los docentes, lo que posibilita una comprensión más profunda de la dinámica de aprendizaje y de los factores que influyen en el rendimiento. Además, destacan que la analítica educativa no debe limitarse a la predicción, sino que debe orientarse hacia la mejora de los procesos educativos.

La revisión de Romero y Ventura (2020) es especialmente relevante porque sintetiza más de una década de evolución de la minería de datos educativa. Los autores confirman que los modelos predictivos —especialmente los basados en técnicas de clasificación— son ampliamente utilizados para identificar a estudiantes en riesgo de fracaso. Señalan, además, que la investigación se ha desplazado progresivamente desde enfoques descriptivos hacia aproximaciones más interpretativas, donde la importancia de las variables y la explicabilidad del modelo adquieren un papel central. Esto es particularmente relevante en contextos institucionales y de política pública, donde los responsables necesitan comprender por qué un modelo predice un determinado resultado.

Peña-Ayala (2019) amplía esta visión, argumentando que la analítica educativa no solo proporciona herramientas predictivas, sino también instrumentos para fundamentar intervenciones y estrategias de mejora. La capacidad de transformar datos en información accionable es uno de los pilares de este campo.

2. Factores determinantes del rendimiento académico

La investigación en psicología educativa, sociología de la educación y economía de la educación ha identificado múltiples factores que influyen en el rendimiento académico. Uno de los estudios más influyentes en esta área es el metaanálisis de Hattie (2009), que integra más de 800 estudios y concluye que el éxito escolar depende de variables relacionadas con el estudiante (motivación, autoestima, esfuerzo), la familia (apoyo parental, expectativas), el profesorado (calidad docente, retroalimentación) y el centro educativo (clima escolar, recursos). Hattie subraya que la implicación activa del estudiante y la calidad de la instrucción tienen un impacto profundo en el rendimiento.

En el contexto de la psicología motivacional, González-Pienda et al. (2014) destacan la importancia de factores como la autoconfianza, la orientación a metas y la atribución causal en el rendimiento. Estos elementos no solo influyen en el aprendizaje inmediato, sino que moldean la percepción del estudiante acerca de sus propias capacidades y su disposición para enfrentar dificultades académicas.

A nivel internacional, los informes de PISA publicados por la OECD (2019) confirman que el nivel socioeconómico del hogar sigue siendo uno de los predictores más robustos del rendimiento académico. Las desigualdades sociales se reflejan directamente en las oportunidades educativas, especialmente en etapas como la educación secundaria obligatoria, donde se intensifica la selección académica. La OECD (2020) insiste en que el análisis del rendimiento académico debe considerar los factores estructurales que condicionan el aprendizaje: desigualdades socioeconómicas, diferencias culturales, características del centro y recursos asignados.

Entre los factores de riesgo, el absentismo escolar destaca como uno de los predictores más sólidos del fracaso académico. Gottfried (2009) muestra que tanto las ausencias justificadas como injustificadas tienen impacto significativo en el rendimiento, debido a la pérdida de tiempo de instrucción y a la desconexión del estudiante con el entorno escolar. Allensworth (2013) profundiza en esta línea, demostrando que el absentismo temprano es un indicador fiable del abandono posterior, incluso más predictivo que las calificaciones previas.

Rumberger (2011), en un estudio seminal sobre abandono educativo, sostiene que el fracaso escolar es un proceso acumulativo que refleja dificultades de larga duración, no episodios aislados. Entiende el abandono como un fenómeno multicausal donde los factores académicos, sociales, familiares y escolares interactúan.

3. Técnicas de aprendizaje automático aplicadas a la educación

El aprendizaje automático ha enriquecido las metodologías tradicionales de análisis educativo al ofrecer herramientas que permiten identificar patrones no lineales y relaciones complejas entre variables. En sus primeras aplicaciones, Kotsiantis et al. (2004) compararon algoritmos de regresión

logística, árboles de decisión y métodos basados en reglas, concluyendo que estos modelos pueden predecir adecuadamente el rendimiento y el riesgo de suspenso.

Posteriormente, Thai-Nghe, Drumond y Schmidt-Thieme (2010) introdujeron algoritmos más avanzados, como las máquinas de vectores de soporte (SVM) y sistemas de recomendación, demostrando su potencial para predecir resultados académicos con alta precisión. Sin embargo, estos algoritmos suelen presentar problemas de interpretabilidad, lo cual puede limitar su utilización en contextos institucionales.

En esta línea, Fauzan et al. (2020) comparan distintos algoritmos de aprendizaje automático y concluyen que los modelos basados en árboles —como decision trees y random forest— presentan un equilibrio óptimo entre precisión y facilidad de interpretación. Esta característica resulta esencial en proyectos donde los resultados deben ser comunicados a responsables educativos que requieren explicaciones claras y comprensibles.

4. Aplicaciones de la analítica educativa en política pública y gestión institucional

En los últimos años, la analítica educativa ha adquirido relevancia en el ámbito de la gestión pública. Daniel (2015) señala que los sistemas educativos pueden beneficiarse del análisis masivo de datos para planificar intervenciones más eficaces, asignar recursos con mayor precisión y evaluar políticas educativas existentes. Este autor subraya que los gobiernos que adoptan metodologías basadas en datos tienden a diseñar políticas más eficientes y equitativas.

Williamson (2017) proporciona una perspectiva crítica sobre la creciente incorporación de datos y algoritmos en la gobernanza educativa. Argumenta que, bien implementada, la analítica educativa puede mejorar la equidad y la calidad del sistema educativo al identificar desigualdades ocultas. Sin embargo, advierte sobre los riesgos asociados a un uso excesivamente tecnocrático que ignore las dimensiones humanas y sociales del aprendizaje.

La OECD (2020) sostiene que las herramientas predictivas pueden contribuir a reducir desigualdades mediante la detección temprana de grupos vulnerables. En particular, resalta su utilidad en etapas como la educación secundaria, donde se definen itinerarios educativos y se intensifican las diferencias de rendimiento.

5. Consideraciones éticas en el uso de modelos predictivos

El empleo de modelos predictivos en educación exige una reflexión ética rigurosa. Slade y Prinsloo (2013) argumentan que los sistemas analíticos deben centrarse en apoyar al alumnado, evitando cualquier forma de etiquetado o estigmatización que pueda limitar su desarrollo educativo. Recuerdan que la analítica educativa no es neutra y que sus resultados pueden tener consecuencias reales en la trayectoria del estudiante.

Pardo y Siemens (2014) destacan la importancia de garantizar la transparencia algorítmica, la protección de datos y la equidad en el uso de los modelos. Señalan que las instituciones deben ser capaces de explicar cómo funcionan los modelos, qué datos utilizan y con qué fin.

Williamson (2017), desde la perspectiva de la gobernanza digital, insiste en que la analítica educativa debe evitar enfoques deterministas que reduzcan los procesos educativos a cifras sin considerar el contexto personal, familiar y social del alumnado. Esta reflexión es especialmente relevante en proyectos que, como el presente, se plantean en un contexto público.

6. Síntesis del Estado del Arte

- La literatura científica en minería de datos educativa, factores de rendimiento académico, aprendizaje automático y políticas educativas coincide en varios puntos fundamentales:
- El rendimiento académico puede predecirse mediante modelos de aprendizaje automático.
- Los factores personales, familiares y escolares influyen de manera significativa en el desempeño.
- Los modelos basados en árboles y la regresión logística ofrecen un equilibrio adecuado entre precisión y explicabilidad.
- La analítica educativa es útil para orientar decisiones tanto pedagógicas como institucionales.
- El uso ético y responsable del análisis predictivo es fundamental para garantizar su impacto positivo.

Esta revisión evidencia que el uso de modelos predictivos con enfoque interpretativo constituye una estrategia metodológicamente sólida y éticamente defendible para el análisis del riesgo académico, justificando plenamente la elección del enfoque utilizado en el presente proyecto.

<u>Bibliografía en formato APA:</u>

Allensworth, E. (2013). The use of early warning indicators for dropout prevention. Journal of Education for Students Placed at Risk, 16(1), 1–12.

Baker, R. S., & Inventado, P. S. (2014). Educational data mining and learning analytics. In J. A. Larusson & B. White (Eds.), Learning Analytics (pp. 61–75). Springer.

Cortez, P., & Silva, A. M. G. (2008). Using data mining to predict secondary school student performance. UCI Machine Learning Repository.

Daniel, B. (2015). Big data and analytics in higher education: Opportunities and challenges. British Journal of Educational Technology, 46(5), 904–920.

Fauzan, R., Abdullah, D., Faiz, N., & Mohamad, M. (2020). Comparison of machine learning algorithms for student performance prediction. Procedia Computer Science, 170, 32–39.

González-Pienda, J. A., Núñez, J. C., González-Pumariega, S., Roces, C., Álvarez, L., González-Pienda, R., & García, M. (2014). Motivación y rendimiento académico. Revista de Psicodidáctica, 19(2), 367–386.

Gottfried, M. A. (2009). Excused versus unexcused absences: Which absence types predict student achievement? Educational Evaluation and Policy Analysis, 31(4), 392–415.

Hattie, J. (2009). Visible learning: A synthesis of over 800 meta-analyses relating to achievement. Routledge.

Kotsiantis, S. B., Pierrakeas, C., & Pintelas, P. (2004). Predicting students' performance using machine learning techniques. Applied Artificial Intelligence, 18(5), 411–426.

OECD. (2019). PISA 2018 results. OECD Publishing.

OECD. (2020). Equity in education: Breaking down barriers to social mobility. OECD Publishing.

Pardo, A., & Siemens, G. (2014). Ethical and privacy principles for learning analytics. British Journal of Educational Technology, 45(3), 438–450.

Peña-Ayala, A. (2019). Learning analytics: Fundamentos y aplicaciones. Springer.

Romero, C., & Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 10(3), e1355.

Rumberger, R. W. (2011). Dropping out: Why students drop out of high school and what can be done about it. Harvard University Press.

Slade, S., & Prinsloo, P. (2013). Learning analytics: Ethical issues and dilemmas. American Behavioral Scientist, 57(10), 1510–1529.

Thai-Nghe, N., Drumond, L., & Schmidt-Thieme, L. (2010). Recommender system for predicting student performance. Procedia Computer Science, 1(2), 2811–2819.

Williamson, B. (2017). Big data in education: The digital future of learning, policy and practice. Sage.

Objetivo general y objetivos específicos

Objetivo general

Desarrollar un modelo predictivo, aplicado a un caso simulado de la Comunidad de Madrid, que permita identificar los factores personales, familiares y escolares asociados al riesgo de suspenso en estudiantes de secundaria, con el fin de ofrecer una herramienta orientativa para la toma de decisiones educativas.

OBJETIVO GENERAL Y OBJETIVOS ESPECÍFICOS

1. Analizar la literatura científica relevante sobre analítica educativa, predicción del rendimiento académico y factores de riesgo escolar para establecer el marco teórico del proyecto.
2. Preparar y transformar el conjunto de datos del Student Performance Dataset mediante procesos de limpieza, codificación y recontextualización que permitan su adaptación al escenario simulado madrileño.
3. Realizar un análisis exploratorio de datos para identificar patrones iniciales, relaciones entre variables y posibles predictores relevantes del rendimiento académico.
4. Entrenar y comparar distintos modelos predictivos, evaluando su desempeño mediante métricas apropiadas.
5. Identificar los factores más influyentes en el riesgo de suspenso a través del análisis de importancia de variables y técnicas de interpretabilidad adecuadas.
6. Generar una segmentación o perfilado de estudiantes que permita visualizar distintos niveles de riesgo académico dentro del caso simulado.
7. Elaborar visualizaciones y representaciones claras del riesgo académico que faciliten la interpretación de los resultados por parte de responsables educativos.
8. Redactar un informe consultivo orientativo, dirigido a la Consejería de Educación de Madrid, que sintetice los hallazgos y proponga posibles líneas generales de actuación sin carácter prescriptivo.
9. Evaluar las implicaciones éticas, de privacidad y equidad asociadas al uso de modelos predictivos en educación, analizando su viabilidad y pertinencia en entornos públicos.

METODOLOGÍA

1. Forma de trabajo

El proyecto se desarrollará mediante un enfoque combinado de analítica educativa, minería de datos y análisis aplicado, siguiendo una lógica progresiva que va desde la revisión teórica hasta la elaboración de un informe consultivo dirigido a la Consejería de Educación de Madrid. El trabajo se realizará íntegramente en RStudio, respetando criterios éticos y garantizando la coherencia técnica en todas las fases.

La estructura del proyecto se articula en cinco bloques: preparación del dataset, análisis exploratorio, modelado predictivo, interpretación de resultados y elaboración de productos consultivos.

2. Aproximación metodológica

La metodología integra técnicas cuantitativas y modelos de aprendizaje automático ampliamente utilizados en el análisis del rendimiento académico.

2.1 Preparación del dataset

Limpieza de datos: tratamiento de valores faltantes, inconsistencias y duplicados.

Codificación de variables categóricas mediante técnicas apropiadas.

Recontextualización del Student Performance Dataset como escenario simulado madrileño.

Conservación estricta de la estructura estadística original.

2.2 Análisis exploratorio de datos

Visualización de distribuciones, correlaciones y patrones relevantes.

Identificación de relaciones entre predictores y la variable objetivo (riesgo de suspenso).

Estudio preliminar de factores como absentismo, apoyo familiar, tiempo de estudio y nivel académico previo.

2.3 Modelado predictivo

Se emplearán y compararán tres modelos:

- Regresión logística: alta interpretabilidad.
- Árbol de decisión: reglas visuales útiles para responsables educativos.
- Random Forest: buen equilibrio entre precisión y estabilidad.

2.4 Evaluación de modelos

Los modelos se evaluarán empleando métricas como:

- Accuracy
- Precision
- Recall
- F1-score
- Matriz de confusión

El criterio de selección prioriza el equilibrio entre rendimiento e interpretabilidad, evitando modelos que resulten opacos para la administración educativa.

2.5 Interpretación y comunicación

- Análisis de importancia de variables.
- Interpretación de coeficientes y reglas de decisión.
- Perfiles de riesgo basados en combinaciones significativas de factores.
- Comunicación mediante un informe consultivo.

2.6 Consideraciones éticas

- El proyecto integra principios de:
- Transparencia
- Responsabilidad
- No estigmatización del alumnado
- Uso orientativo y no determinista del modelo

3. Ejemplos previos (si los hubiere)

La metodología propuesta se apoya en trabajos previos que validan la utilidad de los modelos predictivos en educación:

Kotsiantis et al. (2004) demostraron que la regresión logística y los árboles de decisión son adecuados para predecir el éxito académico.

Thai-Nghe et al. (2010) utilizaron máquinas de vectores de soporte para la predicción educativa con buenos resultados.

Fauzan et al. (2020) confirmaron que los modelos basados en árboles (decision trees y random forest) ofrecen un excelente equilibrio entre precisión e interpretabilidad.

Romero & Ventura (2020) revisan el uso de algoritmos de clasificación y regresión en contextos educativos, destacando su efectividad para identificar a estudiantes en riesgo.

4. Limitaciones metodológicas

Debido a que el proyecto utiliza un caso simulado basado en un dataset real procedente de Portugal, existen limitaciones derivadas de la ausencia de variables específicas del contexto madrileño (por ejemplo, nivel socioeconómico según indicadores españoles, tipología de centros o programas autonómicos de apoyo). No obstante, se mantiene la estructura estadística del dataset y se seleccionan variables que la literatura identifica como universales. La simulación permite evaluar la viabilidad metodológica sin comprometer datos sensibles del sistema educativo.

La combinación de rigor técnico, interpretabilidad, fundamentación ética y orientabilidad institucional asegura que la metodología sea coherente con el propósito consultivo del proyecto y adecuada para su potencial transferencia a contextos educativos reales.

CRONOGRAMA

Fase 1 — Revisión teórica y contextual

Duración: 11 de noviembre – 30 de diciembre

Entregables:

- Selección de bibliografía académica

- Síntesis del estado del arte
- Marco teórico preliminar
- Definición final del caso de consultoría simulado

Fase 2 — Preparación del dataset y análisis exploratorio

Duración: 1 – 31 de enero

Entregables:

- Dataset procesado y adaptado al contexto madrileño simulado
- Conjunto de variables depuradas y codificadas
- Informe de análisis exploratorio con gráficos y patrones iniciales

Fase 3 — Modelado predictivo y validación

Duración: 1 – 28 de febrero

Entregables:

- Modelos entrenados (logística, árbol, random forest)
- Tabla comparativa de métricas (accuracy, precision, recall, F1-score)
- Selección del modelo final

Fase 4 — Interpretación, resultados y visualizaciones

Duración: 1 – 31 de marzo

- Entregables:
- Análisis de factores influyentes (importancia de variables)
- Perfiles de riesgo identificado
- Dashboards
- Borrador del informe consultivo orientativo

Fase 5 — Redacción final y preparación de la defensa

Duración: 1 de abril – mayo

Entregables:

- Memoria completa del TFG
- Versión revisada y corregida
- Presentación para el tribunal